

MARCOS ROSTAN

AI Engineer | LLM Engineer

Buenos Aires, Argentina · rostanmarcos@gmail.com · +54 9 11 2255-4663 · linkedin.com/in/marcosrostan · github.com/MarcosRos002

Autorización laboral: Argentina, Uruguay (Mercosur) · Idiomas: Español (nativo), Inglés (B2)

PERFIL

AI Engineer enfocado en sistemas agénticos en producción, pipelines RAG y automatización con LLMs. Actualmente desarrollando aplicaciones multi-agente con Claude, LangGraph y el Model Context Protocol (MCP) en Move Group. 3+ años previos de experiencia automatizando flujos de datos e integrando sistemas en el sector salud. Estudiante avanzado de la Lic. en Ciencia de Datos en la Universidad de Buenos Aires (UBA).

EXPERIENCIA

AI Engineer / LLM Engineer, Move Group

Jun 2025 – Actualidad

- Construí un agente analítico sobre Claude (62 tools, 40+ fuentes de datos, 260M+ documentos) usado diariamente por el equipo de analistas de Move y clientes seleccionados, reemplazando búsquedas manuales en múltiples bases y reportes ad-hoc de analistas. Diseñé su loop agéntico multi-step, ruteo dinámico de modelos Haiku/Sonnet según complejidad y dispatch de tool-calls en paralelo.
- Desplégé un servicio RAG híbrido sobre pgvector (búsqueda vectorial + full-text con fusión, re-ranking vía Claude Haiku) reemplazando búsquedas manuales en catálogo por consultas en lenguaje natural sobre un corpus interno de encuestas. Implementado con FastAPI, tracing en LangSmith y métricas de latencia P50/P95/P99.
- Diseñé un pipeline de clasificación con LLMs en dos pasadas (Claude Haiku a Sonnet según umbral de confianza) más una capa ASR sobre Groq Whisper, automatizando la auditoría de 200 audios de encuestas semanales (~7 min cada uno) y reemplazando ~23 horas de revisión manual semanal. Orquestado en Celery/Redis con dedup SHA256.

Ingeniero de Software, I+D (Freelance), CetApp Go

Mar 2026 – Actualidad

- Desarrollo features full-stack en una plataforma SaaS HSE multi-tenant (20+ módulos) en sprints ágiles con CI/CD, aplicando desarrollo asistido por Claude Code para acortar ciclos de implementación de features.
- Co-desarrollé la feature de Evaluación de Impacto Ambiental, transformando un flujo manual en planilla a un flujo web guiado con estados de borrador y finalización, eliminando el trabajo en planillas para supervisores de campo.

Data Analyst & Automation Engineer, Sanatorio Clínica Modelo de Morón

Mar 2022 – Jul 2025

- Construí pipelines ETL (Python + SQL) y dashboards automatizados consolidando datos de múltiples sistemas hospitalarios para las áreas de Facturación y Sistemas, eliminando 20+ horas/semana de trabajo manual de reportería.
- Desarrollé un webhook en FastAPI que integra encuestas internas (PostgreSQL) con entrega por WhatsApp vía Botmaker, diseñado para idempotencia y entrega exactly-once de recompensas bajo webhooks concurrentes.
- Desarrollé una plataforma interna de almacenamiento seguro de archivos (FastAPI + AWS S3) con subidas por URL prefirmada soportando archivos de hasta 5 GB, autorización por roles, cifrado en reposo y exposición vía Cloudflare Tunnel (cero puertos inbound).
- Prototipé los primeros casos de uso GenAI de la organización integrando APIs de LLMs (Claude/OpenAI) para parsing de documentos y clasificación de texto.

EDUCACIÓN

Universidad de Buenos Aires (UBA) — Lic. en Ciencia de Datos (en curso)

Abr 2022 – Jul 2027 (estimado)

Instituto La Salette — Técnico Electrónico (programa de 6 años)

2016 – 2021

CERTIFICACIONES

- Claude Code in Action — Anthropic Education (Feb 2026)
- Prompt Engineering — Platzi (Ene 2026)
- Claude Code — Platzi (Feb 2026)
- Algoritmos Avanzados: Grafos y Árboles — Platzi (Ene 2026)

SKILLS TÉCNICOS

Lenguajes: Python, SQL, JavaScript/TypeScript, Bash

LLM & GenAI: APIs de Anthropic Claude, OpenAI, Gemini, Grok; LangChain, LangGraph, LangSmith, Claude Agent SDK, Model Context Protocol (MCP); prompt engineering, evaluación de LLMs

RAG & Vector DBs: pgvector, Chroma, Pinecone; embeddings, búsqueda semántica, retrieval híbrido, re-ranking

ML & Deep Learning: scikit-learn, XGBoost, LightGBM, PyTorch, TensorFlow

Data Engineering: pandas, NumPy, Airflow, pipelines ETL, web scraping, Streamlit

Backend: FastAPI, Flask, Nginx, Celery, REST APIs, webhooks

MLOps & DevOps: Docker, Kubernetes, GitHub Actions (CI/CD), systemd, Prometheus, Grafana

Cloud & Bases de datos: AWS (EC2, S3, Lambda), GCP, Azure DevOps, PostgreSQL, MySQL, MongoDB, Redis